

Kamień milowy 4 - wizualizacja treningu i testów

Dane autora

Imię i nazwisko: Mateusz Adamczak

Numer albumu / grupa: 423062, projekt realizowany samodzielnie

Temat projektu: NaturaVision - lokalny model multimodalny do rozpoznawania roślin i grzybow leśnych

Data przygotowania sprawozdania: 07.05.2026

Zakres dokumentu: ten kamień milowy jest raportem wizualnym. Nie powtarzam tutaj opisu datasetu, pipeline'u, przygotowania treningu ani szczegółów implementacyjnych z poprzedniego kamienia. Celem dokumentu jest pokazanie na wykresach, jak zachował się trening oraz jak model wypada w testach.

1. Cel wizualizacji

W tym raporcie skupiam się na pięciu wykresach:


- przebiegu treningu po Stage 1 i Stage 2,
- porównaniu modelu bazowego z checkpointem po fine-tuningu,
- porównaniu wyników walidacji i testu,
- rozkładzie F1 dla klas na walidacji,
- rozkładzie F1 dla klas na teście.

Najważniejsze pytanie tego kamienia milowego brzmi: czy wykresy potwierdzają, że checkpoint po treningu jest wyraźnie lepszy od modelu bazowego i czy wynik jest stabilny poza zbiorem walidacyjnym.

2. Wykres treningu

Przebieg treningu QLoRA

Porównanie metryk po Stage 1 i Stage 2; loss spada, token accuracy rośnie.



Stage 1: aligner-only, 453 kroki, ok. 16h37m. Stage 2: LLM + aligner, global_step 1359, ok. 35h.

Wykres 1. Podsumowanie treningu.

Wykres pokazuje dwie metryki po kolejnych etapach treningu. Po Stage 2 `eval_loss` spada z `0.1044` do `0.0579`, a `eval_token_acc` rośnie z `0.9642` do `0.9798`.


Interpretacja:

- niższy `eval_loss` oznacza, że model lepiej przewiduje oczekiwaną odpowiedź,
- wyższy `eval_token_acc` oznacza, że model częściej trafia w poprawne tokeny odpowiedzi,
- sama wysoka dokładność tokenów nie wystarcza do oceny klasyfikacji, dlatego najważniejsze są kolejne wykresy testowe.

3. Model bazowy vs checkpoint

Test: model bazowy vs checkpoint QLoRA

Ewaluacja generacyjna na pełnym test.jsonl; wyższe wartości są lepsze.



Wykres 2. Porównanie wyników na zbiorze testowym.

Ten wykres jest najważniejszym podsumowaniem efektu treningu. Checkpoint po fine-tuningu jest wyraźnie lepszy od modelu bazowego w metrykach klasyfikacyjnych.

Najważniejsze różnice:


- **accuracy**: wzrost z 41.3% do 76.9%,
- **macro-F1 known**: wzrost z 32.9% do 75.7%,
- **unknown F1**: wzrost z 67.2% do 84.5%,
- **valid JSON**: oba modele prawie zawsze zachowują poprawny format odpowiedzi.

Wniosek z wykresu: model bazowy dobrze utrzymuje format JSON, ale dopiero fine-tuning znacząco poprawia wybór właściwej klasy.

4. Walidacja vs test

Walidacja vs test checkpointu QLoRA

Zgodność wyników walidacyjnych i testowych ogranicza ryzyko doboru checkpointu pod przypadkowy split.



Wykres 3. Stabilność wyniku między walidacją i testem.


Wyniki walidacyjne i testowe są bardzo zbliżone. To ważne, bo oznacza, że checkpoint nie wygląda na dobrany tylko pod walidację.

Najważniejsze obserwacje:

- **accuracy**: 77.1% na walidacji i 76.9% na teście,
- **macro-F1 known**: 76.1% na walidacji i 75.7% na teście,
- **unknown F1**: 83.4% na walidacji i 84.5% na teście,
- **valid JSON**: 100% w obu przypadkach.

Wniosek z wykresu: wynik testowy jest spójny z walidacją, więc nie widać dużego spadku generalizacji.

5. F1 per klasa - walidacja



Wykres 4. F1 dla kazdej klasy na zbiorze walidacyjnym.


Ten wykres pokazuje, że sredni wynik nie jest rownomierny dla wszystkich klas. Czesc klas jest rozpoznawana bardzo dobrze, a czesc pozostaje wyraznie trudniejsza.

Co widac na wykresie:

- najwyzsze slupki odpowiadaja klasom o charakterystycznym wygladzie,
- nizsze slupki wystepuja przy klasach podobnych wizualnie do innych etykiet,
- metryka F1 dobrze pokazuje klasy problematyczne, bo laczy precision i recall.

Wniosek z wykresu: dalsza poprawa modelu powinna koncentrowac sie nie na wszystkich klasach po rowno, ale na klasach o najnizszym F1.

6. F1 per klasa - test



Wykres 5. F1 dla kazdej klasy na zbiorze testowym.

Wykres testowy potwierdza podobny obraz jak walidacja. Najlepsze klasy utrzymują wysokie F1, a najslabsze klasy nadal sa skupione wokol podobnych wizualnie par.

Najlepiej widoczne zjawiska:

- wiele klas roslin osiaga bardzo wysokie F1,
- czesc grzybow ma nizsze wyniki przez podobienstwo kapeluszy i duza zmienosc zdjec,
- najtrudniejsze klasy sa dobrymi kandydatami do kolejnego hard-negative mining.

Wniosek z wykresu: test nie pokazuje losowego zalamania jakosci. Slabe punkty sa konkretne i mozna je adresowac przez celowane ulepszenie danych.

7. Podsumowanie wizualne

Zestaw wykresow pokazuje trzy najwazniejsze rzeczy:

- trening poprawil metryki wewnetrzne modelu,
- checkpoint po fine-tuningu jest znacznie lepszy od modelu bazowego na realnym tescie generacyjnym,
- wyniki walidacji i testu sa do siebie bardzo podobne, wiec rezultat jest stabilny.

Największy zysk po treningu widac w **macro-F1 known**, czyli w rozpoznawaniu znanych klas. Największy pozostały problem to nierowny wynik dla poszczegolnych klas, szczegolnie tych podobnych wizualnie. Kolejny etap powinien skupic sie na aplikacji mobilnej, tescie na telefonie oraz ewentualnym ulepszaniu danych dla klas o najnizszym F1.